AI4I: vollständige EDA als Quarto-Notebook

Präsentationskopie aus Aufgabe 10.3 · Aufgabe 10.4

Einordnung

APPROVED (26.10.2026). Diese KI-erstellte Präsentationskopie ergänzt den kurzen wissenschaftlichen Bericht und enthält alle zehn Analysen aus 10.3. Codex hat sie nach zwei studentischen PDF-Reviews überarbeitet; der Studierende hat die wissenschaftlichen Inhalte am 26.10.2026 freigegeben. Das Originalnotebook und das studentische Review von 10.3 bleiben unverändert. Die Freigabe von 10.3 gilt nicht als Freigabe dieser neuen Präsentation.

Daten: AI4I 2020, UCI, DOI 10.24432/C5HS5C, CC BY 4.0 (*AI4I 2020 Predictive Maintenance Dataset* 2020). UDI bezeichnet Zeilen, keine Zeitpunkte. Alle 10.000 Beobachtungen werden verwendet.

Der Hauptbericht demonstriert in HTML einklappbaren Code. In dieser Präsentationsfassung bleibt Code zugunsten der Lesbarkeit verborgen; die editierbare Notebookdatei enthält den vollständigen Quellcode. Die folgenden Verteilungen, Paarbeziehungen und Klassenanalysen sind explorativ. IQR-Markierungen sind keine nachgewiesenen Fehler oder Ausfälle.

Vollständige Analysen aus Aufgabe 10.3

Die folgenden zehn Analysen übernehmen die geprüften Berechnungen aus 10.3. Diese neue Präsentationsfassung gehört zu 10.4 und wurde studentisch geprüft, von Codex korrigiert und am 26.10.2026 wissenschaftlich freigegeben. Die Originaldatei bleibt unter `sessions/ch10/ai4i_seaborn.ipynb` erhalten. Die Quelle ist der synthetische UCI-Datensatz AI4I 2020, DOI 10.24432/C5HS5C, CC BY 4.0.

Reproduktion dieser Fassung vom Projektstamm: `scripts/uv.cmd run --offline --locked python scripts/build_exercise_10_4.py`. Quarto erzeugt HTML und PDF über LuaLaTeX; alle Berechnungen werden neu ausgeführt.

Daten und Analyseentscheidungen

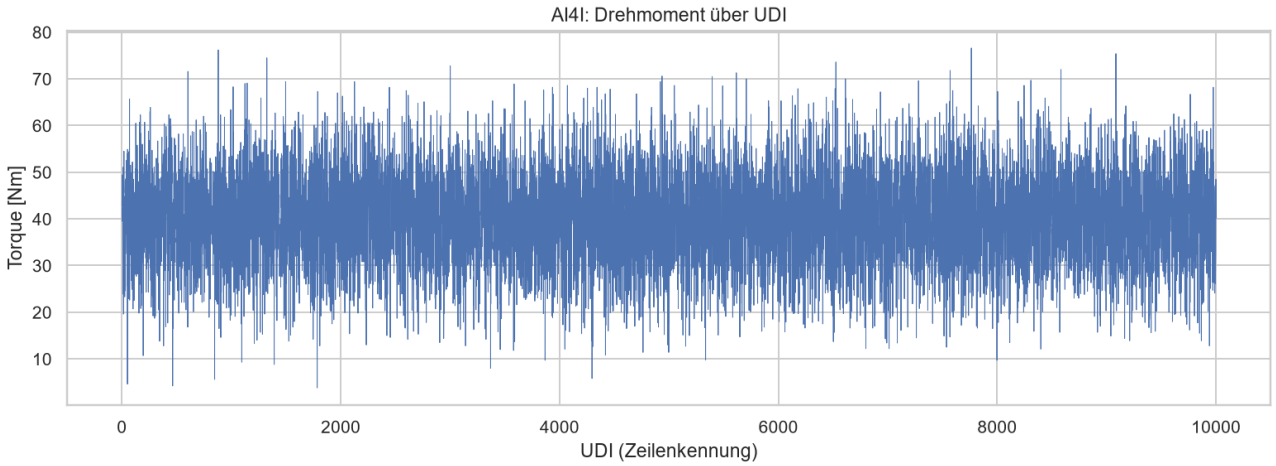
Der geprüfte Loader aus 10.2 kontrolliert unveränderte Rohbytes, Spalten, Zeilenzahl und Kennungen. `numeric` enthält ausschließlich die drei Messgrößen; UDI bleibt separat für die ausdrücklich verlangte Linie. Keine Imputation, Normalisierung, Filterung oder Stichprobe. UDI ist **kein Zeitstempel**. Ein Seed reproduziert nur den Jitter, nicht eine vermeintliche Messunsicherheit.

```
Daten: 10000 Zeilen, drei Messgrößen; Seaborn 0.13.2
SHA256: dc6630cd9b1f0f853922fad78a1b6436570d3f1ec863f1dd5c4340ac56bc8a8e
```

	Torque [Nm]	Rotational speed [rpm]	Air temperature [K]
count	10000.000000	10000.000000	10000.000000
mean	39.986910	1538.776100	300.004930
std	9.968934	179.284096	2.000259
min	3.800000	1168.000000	295.300000
25%	33.200000	1423.000000	298.300000
50%	40.100000	1503.000000	300.100000
75%	46.800000	1612.000000	301.500000
max	76.600000	2886.000000	304.500000

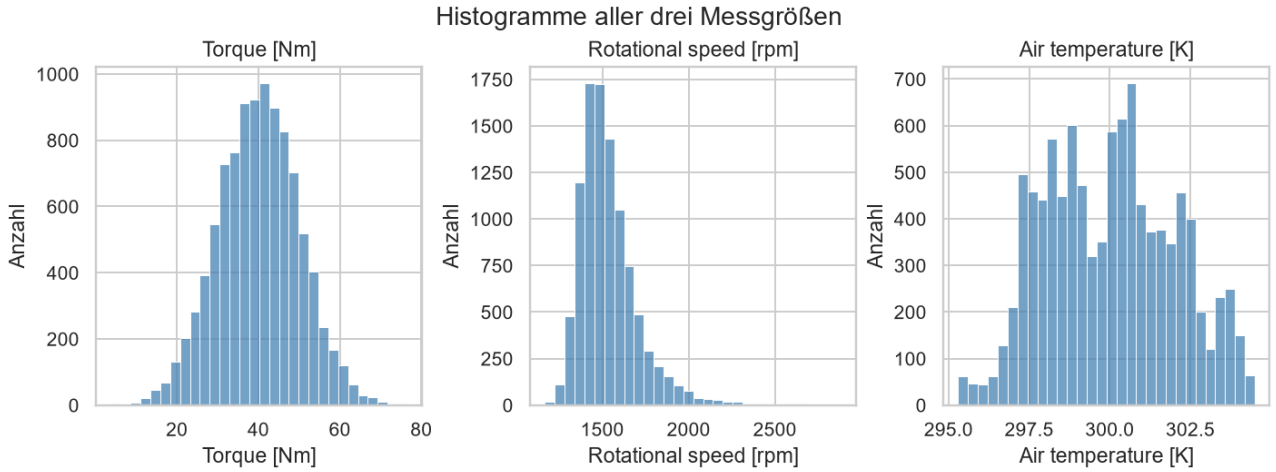
1. Drehmoment über UDI

Die Linie verbindet alle Beobachtungen in Originalreihenfolge. `estimator=None` verhindert Aggregation; es wird kein Unsicherheitsband dargestellt. Dichte Schwankungen über eine Zeilenkennung dürfen nicht als zeitlicher Prozess interpretiert werden.



2. Verteilungen – Histogramme

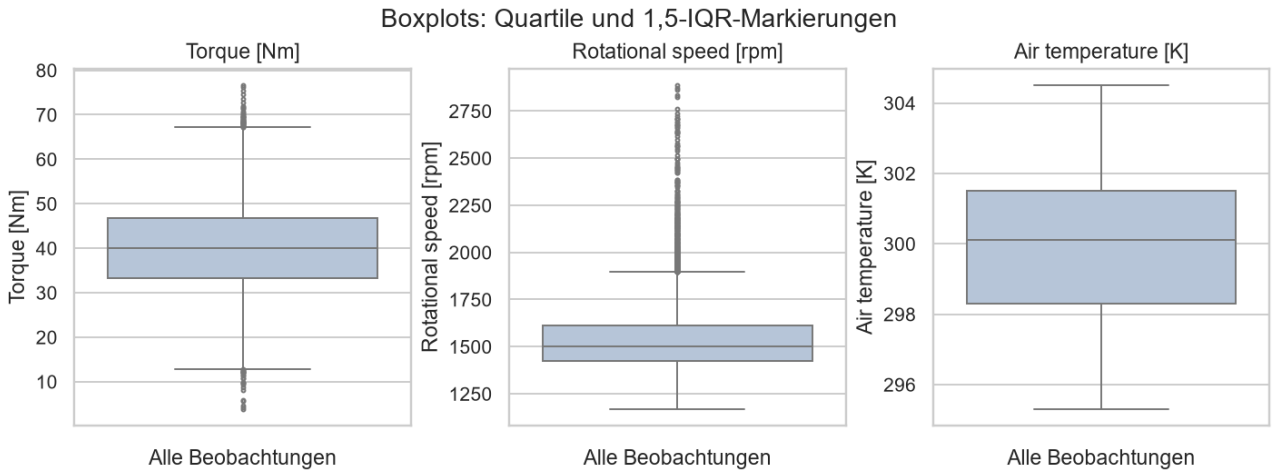
Je Messgröße werden 30 Bins verwendet. Anzahl und Grenzen der Bins beeinflussen den visuellen Eindruck. Die x-Achsen behalten ihre Einheiten und eigenen Skalen; die y-Achsen zählen Beobachtungen, nicht Wahrscheinlichkeitsdichten.



3. Boxplots und auffällige Werte

Boxplots verdichten Median, Quartile und Streuung. Punkte außerhalb der 1,5-IQR-Zäune sind hier **heuristisch auffällig**, nicht automatisch fehlerhaft. Die jeweilige Messgröße erhält eine eigene Achse mit Originaleinheit.

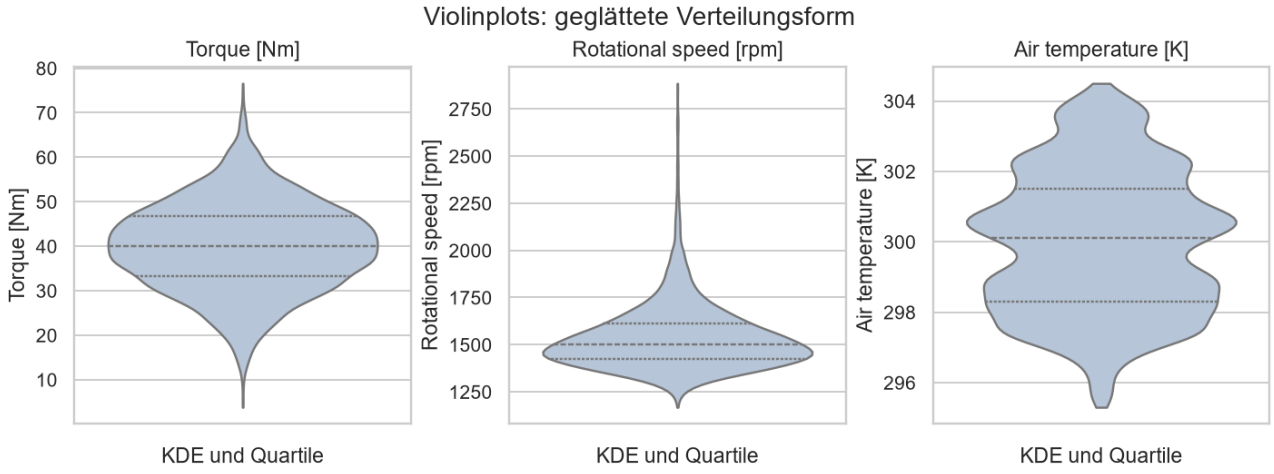
Numerische Randfälle: Die Berechnung nutzt eine absolute Toleranz von 1e-10 in der jeweiligen Einheit; der Boxplot verwendet `whis=1.5+1e-12`, um Werte auf den theoretischen Zäunen nicht durch Rundungsfehler als außerhalb zu zeigen. Diese Änderungen sind gegenüber der Messauflösung vernachlässigbar. Bei Torque liegen vier Werte auf 12,8 und einer auf 67,2 Nm; sie gelten nicht als Ausreißer.



	q1	q3	Untergrenze	Obergrenze	Markiert
Drehm. [Nm]	33.2	46.8	12.8	67.2	64
Drehzahl [rpm]	1423.0	1612.0	1139.5	1895.5	418
Lufttemp. [K]	298.3	301.5	293.5	306.3	0

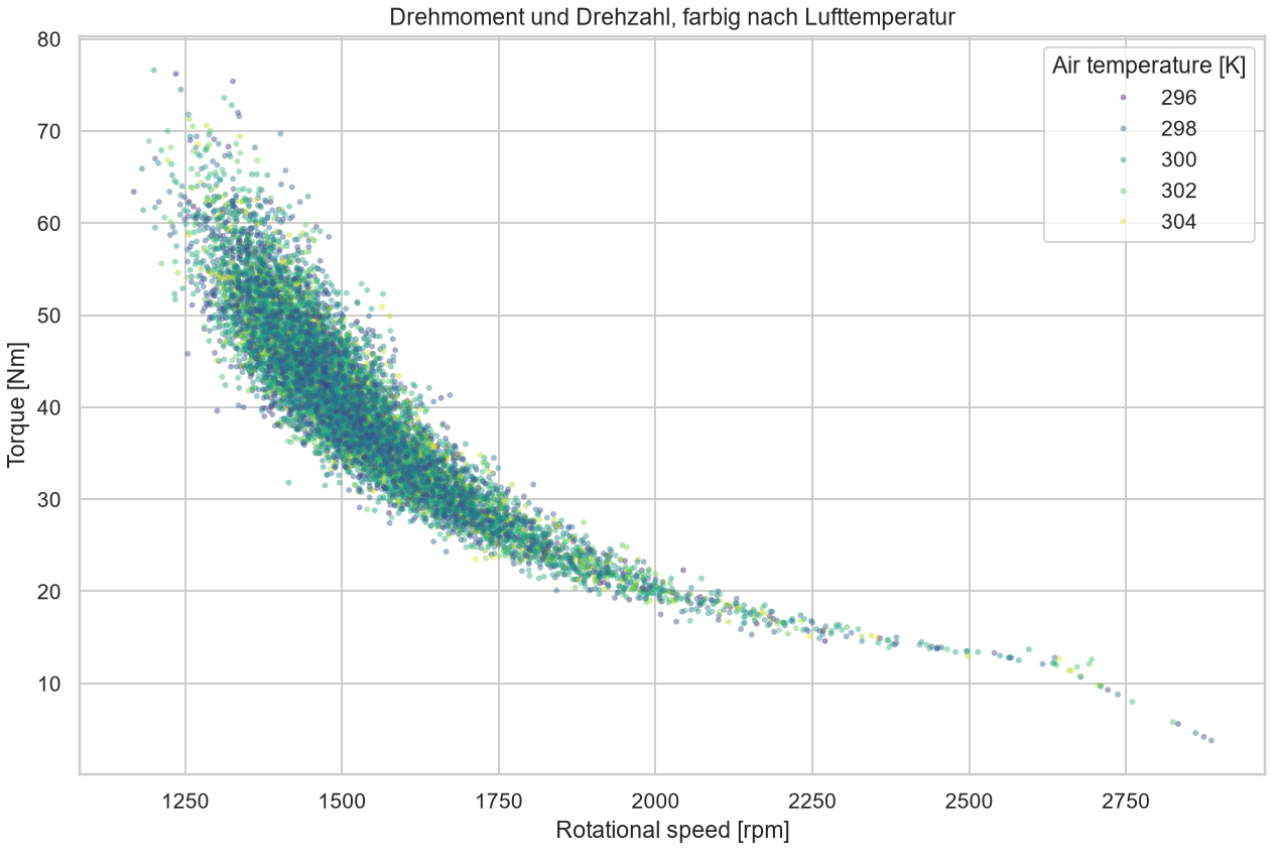
4. Violinplots im Vergleich zu Boxplots

Die Violinbreite ist eine Kernel-Dichteschätzung (KDE), keine Anzahl einzelner Beobachtungen. Bandbreite und Stichprobe beeinflussen die Form. `cut=0` begrenzt die Darstellung auf beobachtete Werte; innere Quartile ergänzen die Dichte. Gegenüber Boxplots wird Verteilungsform sichtbar, aber auch geglättet und damit von einer zusätzlichen Modellierungsentscheidung abhängig.



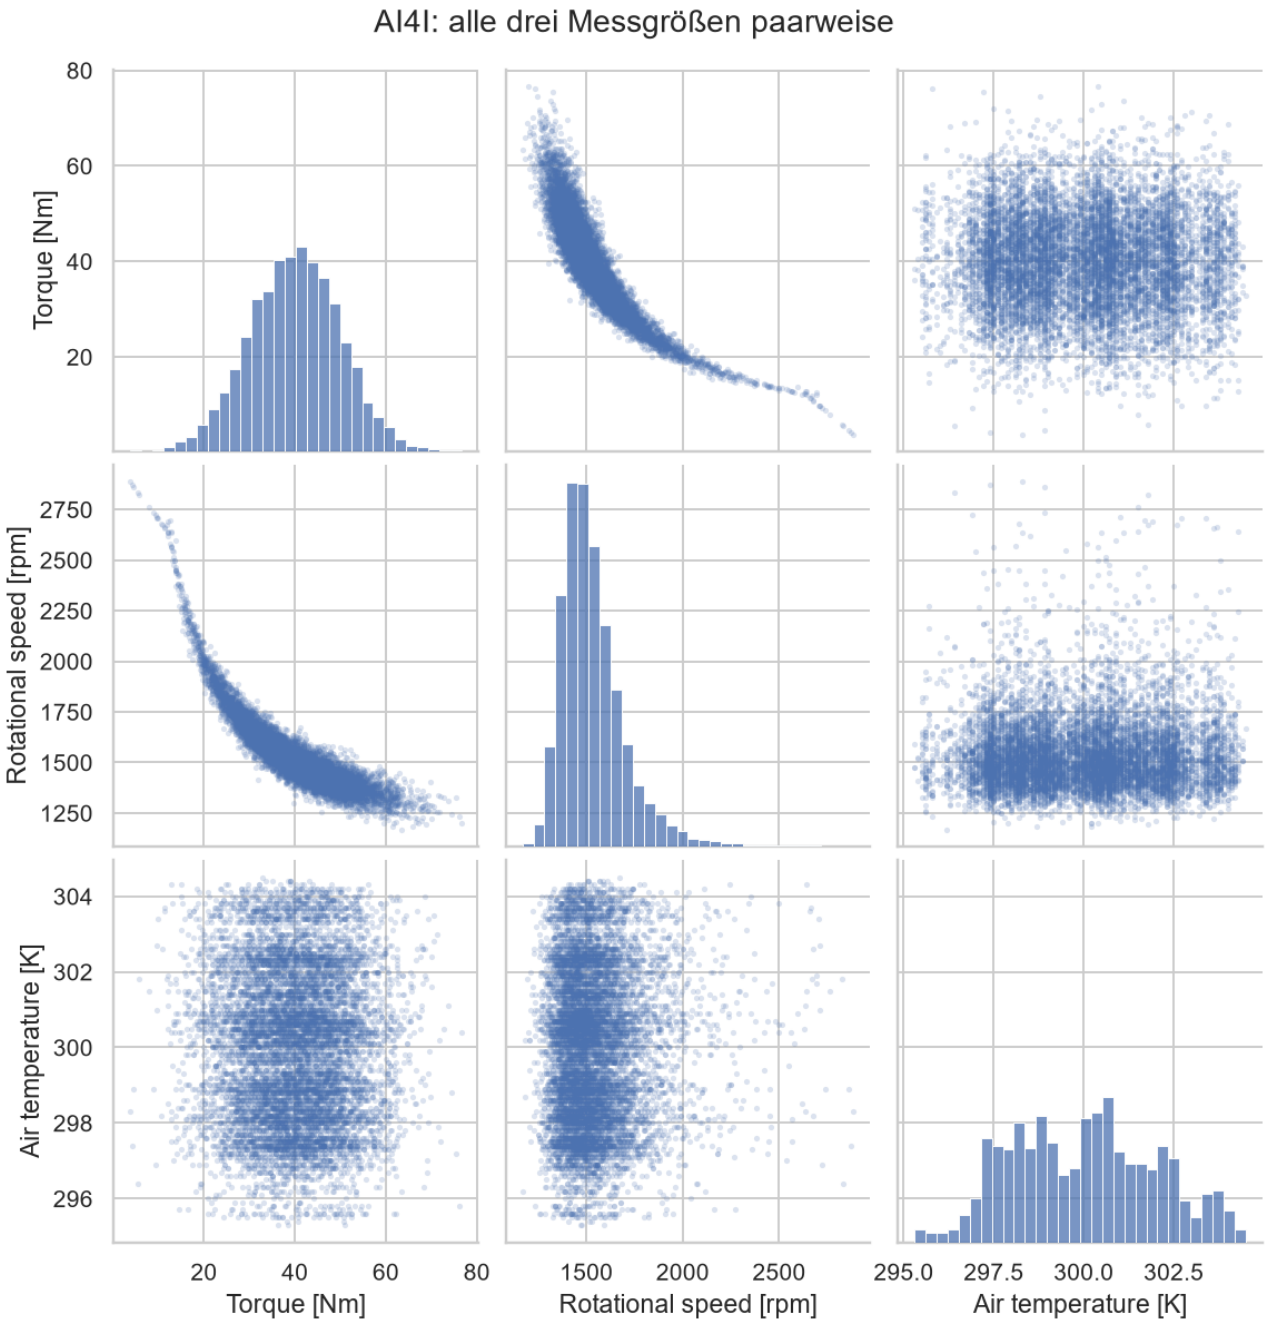
5. Torque gegen Rotational speed – Temperatur als Farbe

`sns.scatterplot` bildet Drehzahl auf x, Drehmoment auf y und Lufttemperatur auf die kontinuierliche Farbskala ab. Transparenz begrenzt die Überlagerung aller 10.000 Punkte. Die Farblegende zeigt Kelvin; Farbunterschiede beweisen keinen Einfluss der Temperatur.



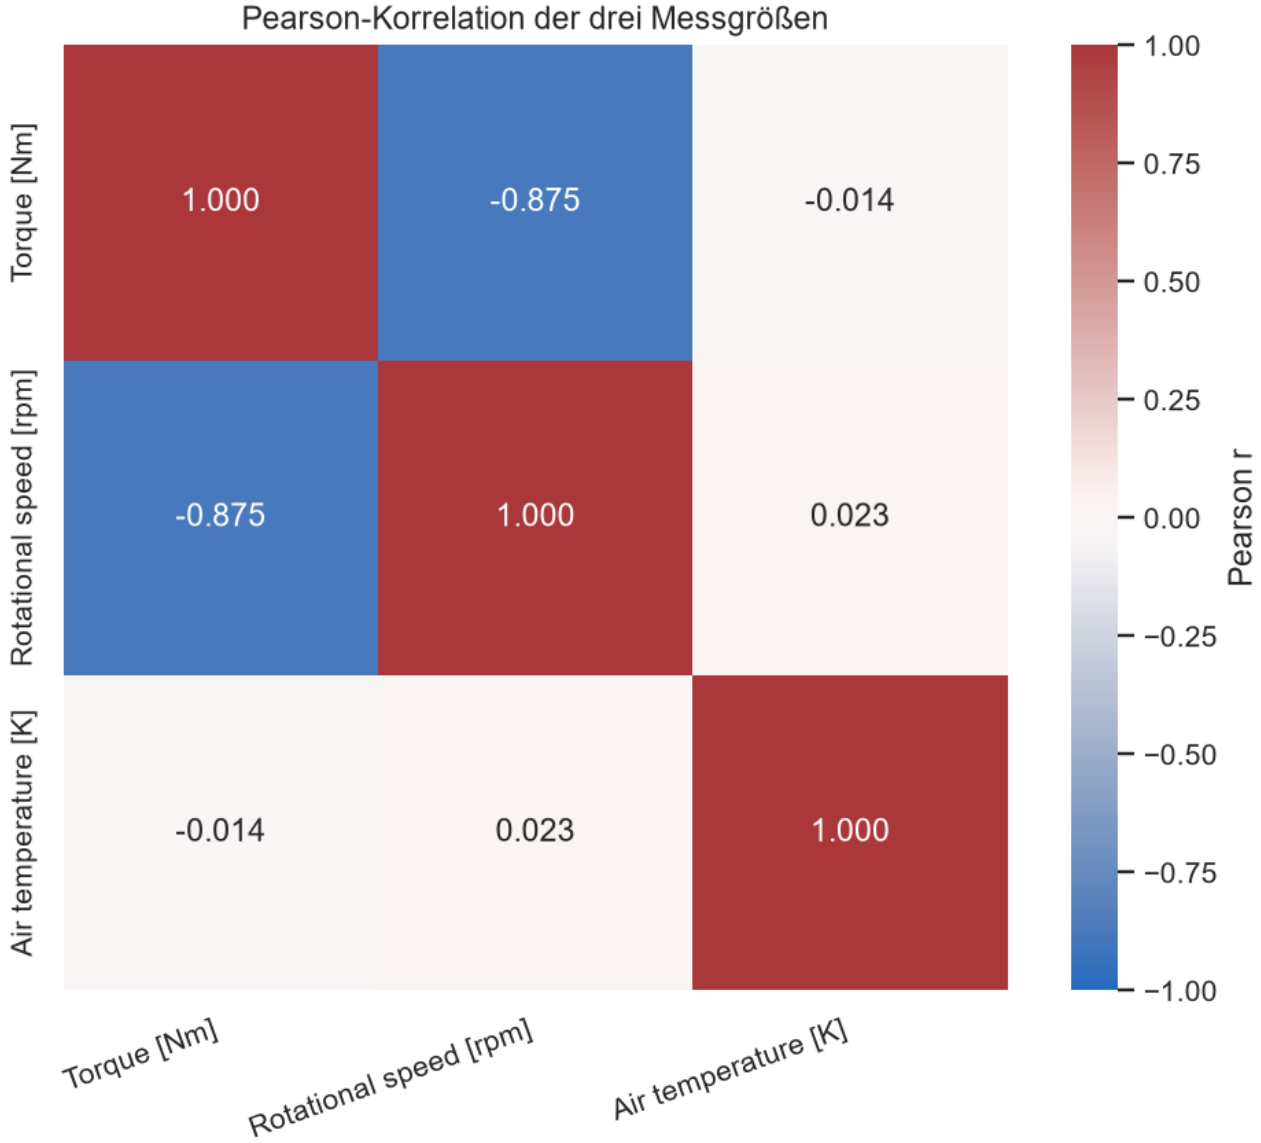
6. Paarweise Beziehungen

`sns.pairplot` zeigt alle drei Messgrößen, ihre paarweisen Punktwolken und Histogramme auf der Diagonalen. Unterschiedliche Achsenskalierungen sind nötig, weil Einheiten und Wertebereiche verschieden sind. Alle Beobachtungen werden verwendet; dichte Bereiche können sich weiterhin überdecken.



7. Pearson- und Spearman-Korrelation

Pearson misst den linearen Zusammenhang. Die **Pearson-Heatmap** verwendet die feste Skala −1 bis +1 und annotiert alle Koeffizienten. Das stärkste Paar wird nach dem Betrag der Off-Diagonale gewählt. Die nachfolgende Tabelle zeigt ausdrücklich **Spearman-Rangkorrelationen**. Spearman ergänzt die Betrachtung monotoner, möglicherweise nichtlinearer Muster. Keine Korrelation belegt Kausalität.



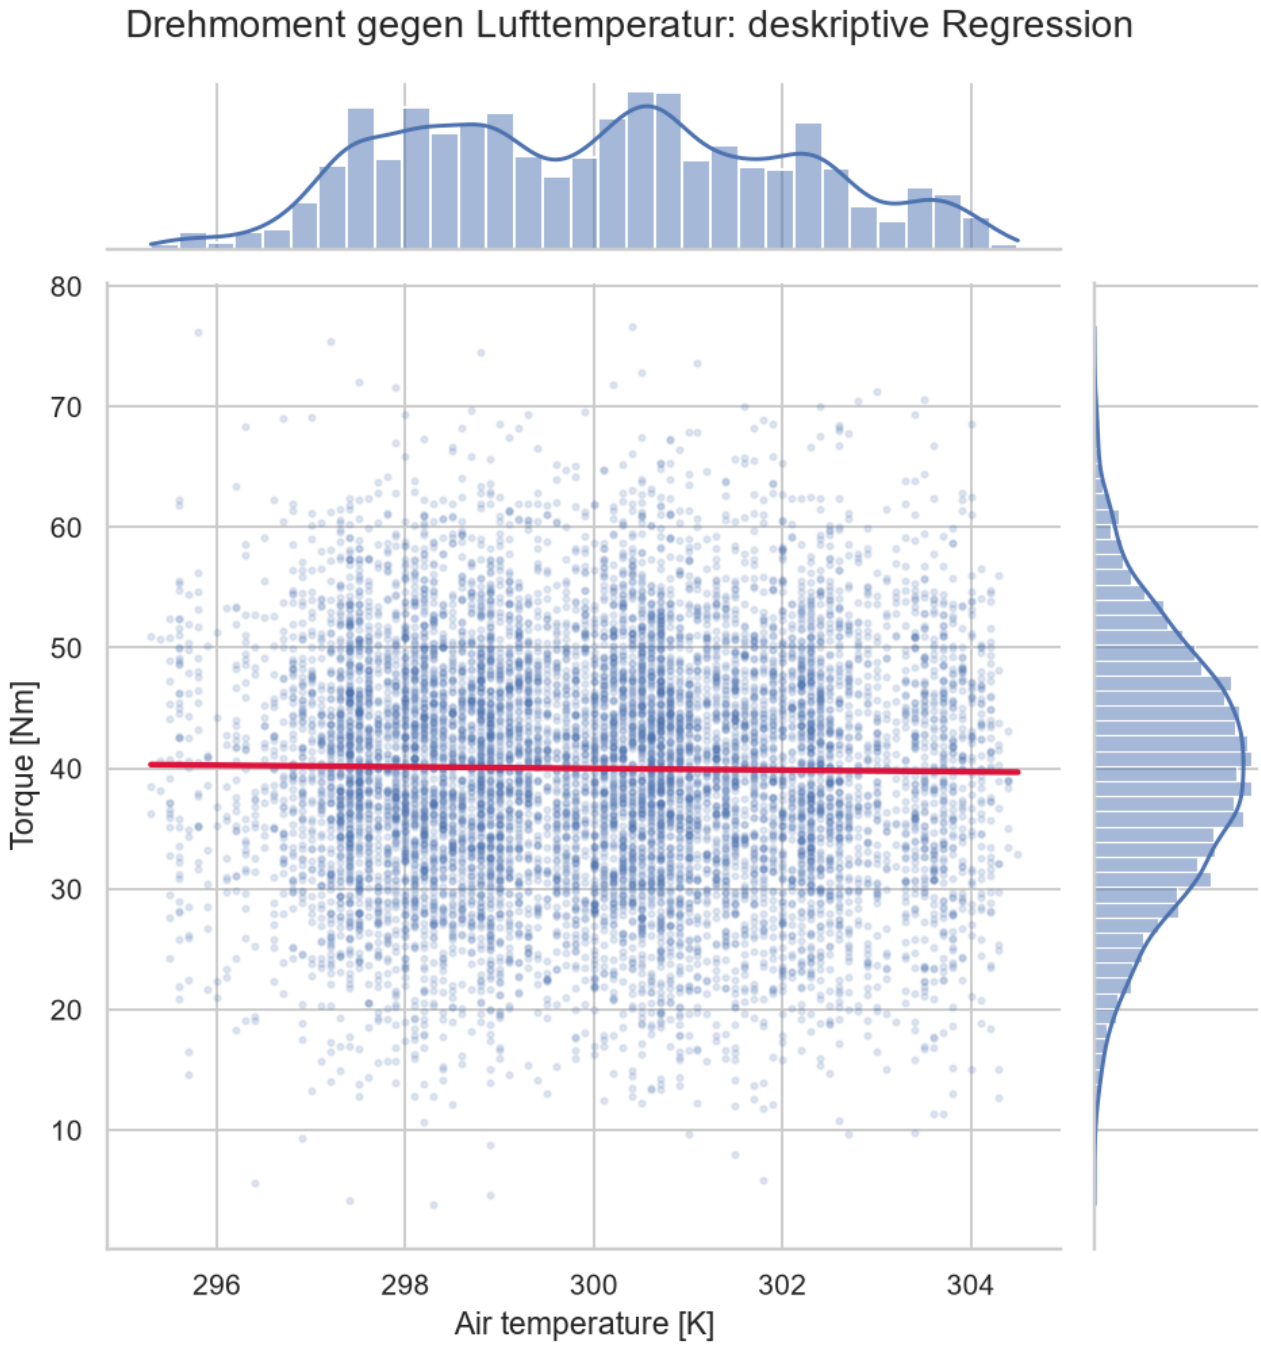
Spearman-Rangkorrelation (mittlere Ränge bei Bindungen)

Messgröße	Torque [Nm]	Rotational speed [rpm]	Air temperature [K]
Torque [Nm]	1.0000	-0.9165	-0.0118
Rotational speed [rpm]	-0.9165	1.0000	0.0137
Air temperature [K]	-0.0118	0.0137	1.0000

Stärkstes Pearson-Paar: **Torque [Nm] / Rotational speed [rpm]**, r = **-0.8750**. Spearman dafür: **-0.9165**.

8. Jointplot mit Regressionsgerade

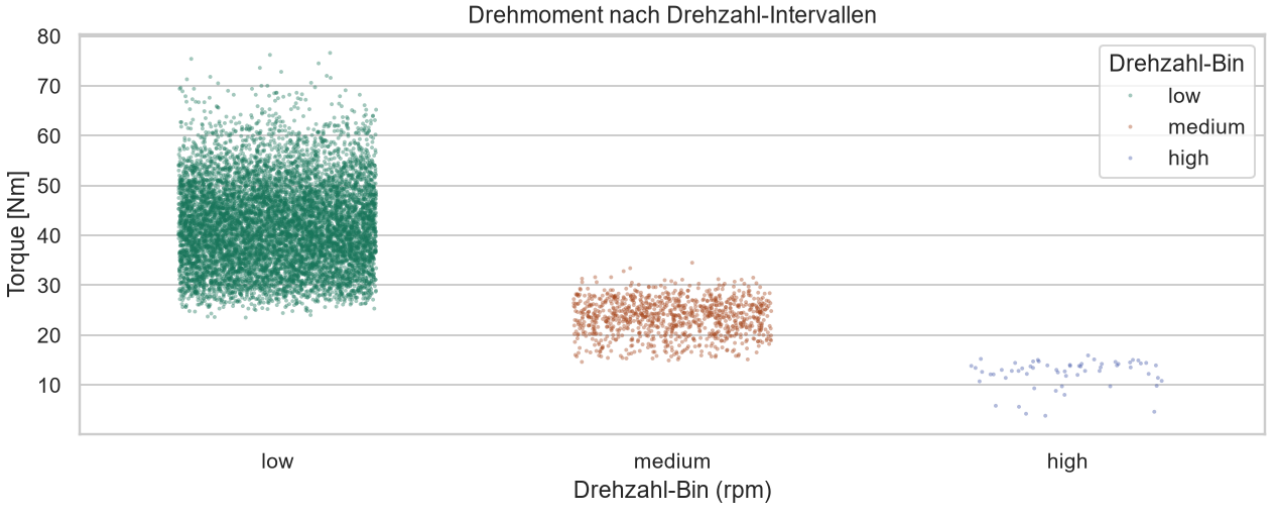
Torque wird gegen Air temperature geplottet, inklusive Randverteilungen. Die Gerade ist eine deskriptive lineare Zusammenfassung, kein Kausalmodell. Ein Konfidenzband wird weggelassen (`ci=None`), da hier keine ungeprüfte Unabhängigkeitsannahme in eine inferenzstatistische Aussage übersetzt werden soll.



9. Stripplot nach Drehzahl-Bins

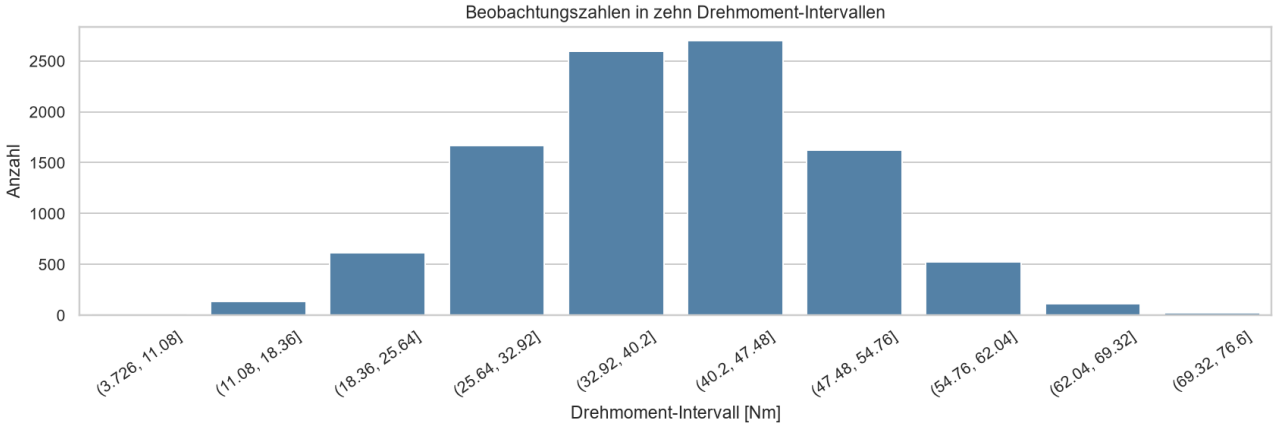
`pd.cut` teilt den beobachteten Drehzahlbereich in drei Intervalle gleicher Breite, benannt low/medium/high. Das sind **keine Quantile**; Gruppengrößen dürfen sich stark unterscheiden. Die exakten Grenzen und Häufigkeiten werden ausgegeben. Alle Drehmomentwerte erscheinen als Punkte, Farbe und x-Position kennzeichnen denselben Bin. Jitter (Seed 42) dient ausschließlich der Darstellung.

speed_band	lower	upper	count
low	1166.282000	1740.666667	8965
medium	1740.666667	2313.333333	975
high	2313.333333	2886.000000	60



10. Countplot der Torque-Intervalle

Die zehn Intervalle gleicher Breite decken alle Drehmomentwerte ab; die Intervallgrenzen sind zusätzlich als JSON gespeichert. `pd.cut` erweitert bei ganzzahliger Bin-Anzahl den Rand leicht, damit die Extremwerte eingeschlossen sind. Der Countplot zählt alle 10.000 Zeilen ohne Filterung.



torque_band	count
(3.726, 11.08]	13
(11.08, 18.36]	137
(18.36, 25.64]	614
(25.64, 32.92]	1666
(32.92, 40.2]	2597
(40.2, 47.48]	2697
(47.48, 54.76]	1624
(54.76, 62.04]	521
(62.04, 69.32]	112
(69.32, 76.6]	19

Beobachtungen – tatsächlich berechnete Kennzahlen

Die folgende Tabelle ergänzt die visuelle Beurteilung mit reproduzierbaren Kennzahlen. IQR-Flags werden nicht entfernt. Skewness beschreibt Asymmetrie, ist aber weder Normalitätstest noch Beleg einer bestimmten Verteilung.

	flagged_count	skewness	minimum	maximum
Torque [Nm]	64	-0.009517	3.8	76.6
Rotational speed [rpm]	418	1.993171	1168.0	2886.0
Air temperature [K]	0	0.114274	295.3	304.5

Auffällige Werte: Torque 64, Rotational speed 418, Air temperature 0 außerhalb der 1,5-IQR-Zäune. **Stärkste Beziehung:** Torque [Nm] / Rotational speed [rpm], Pearson r = -0.8750. Drehmoment-Skewness -0.010, Drehzahl-Skewness 1.993, Temperatur-Skewness 0.114.

Beobachtete Muster und Grenzen

Die folgenden Aussagen wurden nach tatsächlicher Ausführung und Sichtprüfung von Codex formuliert und sind keine studentische Beurteilung:

1. **Auffällige Werte:** Die Boxplots zeigen Randwerte bei Torque und vor allem im oberen Drehzahlbereich. Mit der dokumentierten Randtoleranz werden 64 Torque-, 418 Drehzahl- und 0 Temperaturwerte markiert. Das sind Heuristiken, keine bewiesenen Fehler; kein Wert wird entfernt.
2. **Stärkste Beziehung:** Torque und Rotational speed sind deutlich negativ verbunden (Pearson −0,8750; Spearman −0,9165). Scatter und Pairplot zeigen eine gekrümmte, monoton fallende Punktwolke. Ein linearer Koeffizient fasst diese Form nur teilweise zusammen. Die Temperatur-Korrelationen liegen dagegen nahe null; die Jointplot-Gerade ist nahezu horizontal. Das beweist weder völlige Unabhängigkeit noch einen fehlenden physikalischen Einfluss.
3. **Verteilungsformen:** Torque ist ungefähr symmetrisch und glockenförmig (Skewness −0,010); Normalität ist damit nicht bewiesen. Die Drehzahl hat einen langen rechten Schwanz (Skewness 1,993). Temperatur zeigt mehrere unregelmäßige Häufungen trotz kleiner Schiefe (0,114); kleine Schiefe allein bedeutet keine Normalverteilung.
4. **Binning und Darstellung:** Die drei gleichbreiten Drehzahlgruppen enthalten 8965/975/60 Beobachtungen. Der Stripplot verdeutlicht sinkende Torque-Werte über diese Gruppen, aber keine kontrollierten Effekte. Histogramm-Bins und KDE-Bandbreite beeinflussen die sichtbare Form; insbesondere Violinbreiten sind keine direkten Häufigkeiten. Transparenz/Jitter beseitigen Überlagerung nicht vollständig.

Die Daten sind synthetisch, UDI ist kein Zeitstempel. Es werden weder Kausalität, Signifikanz noch ein zugrunde liegender Mechanismus nachgewiesen. Regression und Korrelationsmatrizen sind rein deskriptiv. Die Freigabe der ursprünglichen Aufgabe 10.3 ersetzt kein Review dieser neuen Präsentationsfassung.

Lernfragen zur Analyse

1. Sind alle verlangten Diagramme und alle drei Messgrößen vorhanden und lesbar?
2. Wie unterscheiden sich Boxplot und Violinplot, und warum sind IQR-Flags keine bewiesenen Fehler?
3. Was zeigen Scatter, Pairplot und Pearson/Spearman über die stärkste Beziehung und mögliche Nichtlinearität?
4. Wie beeinflussen gleiche Bin-Breiten, ungleiche Gruppengrößen, Jitter und KDE die Darstellung?
5. Welche Schlussfolgerungen sind wegen synthetischer Daten und fehlender Zeitinformation nicht zulässig?

APPROVED (26.10.2026). Die wissenschaftlichen Inhalte wurden nach den studentischen Reviews ausdrücklich freigegeben.

Grenzen und Review

Die starke inverse Drehmoment-Drehzahl-Beziehung ist deskriptiv. Die Daten sind synthetisch, eine Übertragung auf reale Maschinen oder ein Kausalitätsnachweis folgen daraus nicht. Schwache Temperaturkorrelationen beweisen keine Unabhängigkeit. Bei den Klassenplots beeinflussen die Grenzen die sichtbaren Häufigkeiten; Zeilen werden nicht entfernt. Die numerische IQR-Toleranz schützt exakte Grenzwerte vor Gleitkommafehlern. Diese Präsentationskopie wurde nach studentischem Review von Codex überarbeitet und am 26.10.2026 wissenschaftlich freigegeben. **APPROVED (26.10.2026)**.

Literatur

AI4I 2020 Predictive Maintenance Dataset. 2020. UCI Machine Learning Repository. https://doi.org/10.24432/C5HS5C.